



中國人民大學  
RENMIN UNIVERSITY OF CHINA

# 房价预测建模项目

汇报人：谢丽媛

2025年6月

# 模型亮点-数据预处理

## “环线”预处理方案

### □ 统一表达:

将不同表达但含义相同的值统一（如“内环内”→“一环内”）

### □ 有序编码:

数值编码保留环线的距离关系（数值越大离市中心越远）

### □ 衍生特征:

创建是否核心区二元特征（编码值 $\leq 3$ 的视为核心区）

## “梯户比例”预处理方案

### □ 结构化提取:

从“X梯Y户”格式中提取电梯数量和每梯户数

示例：“八梯六户”→ 电梯数量=8，每梯户数=6

### □ 核心指标计算:

电梯服务密度 = 总户数 / 电梯数量

### □ 衍生特征创建:

拥挤度分级：非常宽松( $\leq 4$ 户/梯)、舒适、一般、拥挤、非常拥挤( $> 20$ 户/梯)

### □ 异常值处理:

电梯数量超过20的设为20

每梯户数超过100的设为100

# 模型亮点-数据预处理

## "建筑面积"和"套内面积"预处理方案

### □ 数据清洗:

移除" $\text{m}^2$ "符号并转换为float类型

处理极端小面积 ( $<15\text{m}^2$  设为  $15\text{m}^2$ )

### □ 衍生特征:

得房率: 套内面积/建筑面积 (核心指标)

公摊面积: 建筑面积-套内面积

面积等级: 按市场标准分段 ( $50/90/144/200\text{m}^2$  为界)

是否豪宅二值变量:  $144\text{m}^2$  为分界线 (中国普通/非普通住宅标准)

### □ 缺失值处理:

使用中位数得房率估算缺失的套内面积

### □ 异常值处理:

确保套内面积  $\leq$  建筑面积

# 模型亮点-数据预处理

## 训练集"房屋户型"预处理方案

### □ 数据清洗:

统一"房间"→"室"的表述

修复可能的文本错位 (如"卫室"→"卫 室")

### □ 异常值处理:

卧室数超过10的设为10 (应对"16室"等异常)

卫生间数不超过卧室数+3 (应对"14卫"等异常)

### □ 衍生特征:

总房间数: 卧室+客厅

卧室卫生间比: 反映居住舒适度

是否标准户型: 标记功能齐全的户型

是否豪宅户型: 卧室 $\geq 4$ 的户型

## 训练集"房屋朝向"预处理方案

### □ 特征提取:

主朝向: 按价值优先级选择 (南>东南>东>...)

优质标志: 南、东南、东朝向为优质

### □ 按现实逻辑编码:

中国购房者偏好: 南>东南>东>西南>北>西>东北>西北

南北通透户型有显著溢价

# 模型评估

## (一) 线性模型

模型	RMSE	$R^2$
LinearRegression	$6.44 \times 10^7$ (异常)	$-5.22 \times 10^{15}$ (异常)
<b>Ridge</b>	<b>0.5186</b>	<b>0.6611</b>
Lasso	0.7881	0.2176

❑ 普通线性回归失效  
 $R^2$ 为负，比均值预测更差

❑ Ridge表现最优  
说明共线性严重  
→ 必须使用正则化

# 模型评估

## (二) 模型训练与选择

### □ 代码架构设计

```
pipeline = Pipeline([
    ('preprocessor', preprocessor), # 特征工程管道
    ('model', model)               # 预测模型
])
```

- **统一接口**: 将特征处理与模型训练封装为端到端流程
- **可复用性**: 支持快速切换不同模型

### □ 自动化调参流程

```
GridSearchCV(
    pipeline,                # 包含预处理+模型的完整流程
    param_grids[name],       # 对应模型的参数网格
    cv=5,                   # 5折交叉验证
    scoring='neg_rmse',     # 评估指标: 负RMSE (越小越好)
    n_jobs=-1,              # 使用所有CPU核心并行计算
    verbose=1               # 输出调参过程日志
)
```

# 模型评估

## (三) 线性模型与树模型

模型名称	RMSE	R <sup>2</sup>	最佳参数	训练耗时 (拟合次数)
RandomForest	0.1917	0.9532	<code>{'model__max_depth': None}</code>	15 fits (3×5 folds)
LightGBM	0.2209	0.9379	<code>{'model__learning_rate': 0.1, 'model__num_leaves': 63}</code>	15 fits (3×5 folds)
Ridge	0.5146	0.6629	<code>{'model__alpha': 1}</code>	15 fits (3×5 folds)
Lasso	0.5452	0.6217	<code>{'model__alpha': 0.001}</code>	45 fits (9×5 folds)
ElasticNet	0.5321	0.6398	<code>{'model__alpha': 0.001, 'model__l1_ratio': 0.5}</code>	45 fits (9×5 folds)
XGBoost	0.2083	0.9426	<code>{'model__learning_rate': 0.1, 'model__max_depth': 6}</code>	30 fits (6×5 folds)

# 模型评估

## (四) 最优模型：随机森林

```
RandomForest - RMSE: 0.1917, R2: 0.9532  
Best params: {'model__max_depth': None}  
Fitting 5 folds for each of 6 candidates, totalling 30 fits
```

### □ 模型性能评估：

预测较准确，拟合效果较好。

### □ 最佳超参数：

```
Best params: {'model__max_depth': None}
```

•max\_depth=None：决策树不限制最大深度。

### □ 交叉验证：

- 5 folds**：使用了 5 折交叉验证（将数据分为 5 份，轮流用 4 份训练，1 份验证）。
- 3 candidates**：对 max\_depth 参数尝试了 3 种可能的取值（[10, 20, None]）。
- 15 fits**：总共训练了 15 次模型（5 折 × 3 种参数组合）。



# 模型表现对比

## (五) 模型优化：随机森林

```
param_grids = {  
    'RandomForest': {  
        'n_estimators': [100, 150],          # ↑ 增加树的数量  
        'max_depth': [15, 20, None],         # 动态深度控制  
        'min_samples_split': [2, 5, 10],     # 新增分裂控制  
        'min_samples_leaf': [1, 2, 4],       # 新增叶节点约束  
        'max_features': ['sqrt', 0.8],       # 新增特征采样策略  
        'bootstrap': [True, False]           # 新增样本采样开关  
    }  
}  
# 采用RandomizedSearchCV加速搜索:  
RandomizedSearchCV(n_iter=15, cv=3, n_jobs=4)
```

1. 增加树数量(n\_estimators=150)未导致过拟合
2. 限制min\_samples\_split=5提升泛化能力
3. 深度控制 max\_depth平衡模型复杂度与过拟合风险

指标	初始版本	优化版本
RMSE	0.1917	0.1909
R <sup>2</sup>	0.9532	0.9536
训练效率	15次拟合	45次拟合
最佳参数组合	仅max_depth	6参数联合优化